EKSPLORASI DATA

Semester Genap 2025/2026

Pendahuluan

Data exploration merupakan salah satu tahap yang ada di dalam metodologi *data mining*. *Data exploration* adalah suatu tahap yang digunakan untuk memahami karakteristik, struktur, dan pola dari dataset yang digunakan. Tahap ini melibatkan pemeriksaan distribusi data, identifikasi nilai yang hilang (missing values), pencarian outlier, serta analisis hubungan antar variabel. Di dalam metodologi CRISP-DM, *data exploration* dilakukan sertelah *business understanding*, pada SEMMA setelah tahap *sample*, dan OSEMN serelah tahap *scrub*. Sedangkan dalam KDD tidak dijelaskan secara eksplisit, akan tetapi biasanya dilakukan pada tahap *data preparation* sebelum tahapan *feature engineering*.

Tujuan *Data Exploration*

1. Memahami struktur data
   Dengan *data exploration*, kita dapat mengetahui jenis & jumlah variabel/ *feature*, tipe data dari setiap variabel, dan jumlah objek/ subjek/ observasi yang ada dalam data yang digunakan.
2. Menemukan pola awal
   Dari proses ini dapat diketahui tren, persebaran/ distribusi, hubungan antar variabel dari data yang digunakan
3. Mengidentifikasi kualitas data
   Dengan melakukan pengecekan kualitas data, maka dapat ditemukan apakah terdapat *missing value*, data duplikat, kesalahan pencatatan (*inconsistence data*), atau *outlier* pada data.
4. Menentukan strategi analisis
   Data exploration dapat membantu dalam menentukan metode/ algoritma yang tepat sesuai dengan karakteristik data yang digunakan.

Manfaat *Data Exploration*

1. Memberikan gambaran awal tentang dataset.
2. Membantu mencegah kesalahan analisis akibat data yang tidak valid.
3. Menjadi dasar untuk pemodelan yang lebih akurat.
4. Mempercepat proses pengambilan keputusan berbasis data.

Tahapan dalam *Data Exploration*

1. Memahami *dataset*, seperti mengetahui jumlah baris dan kolom dari data, nama variabel, dan tipe data (numeric, categorical, dst).
2. Statistika deskriptif, misalnya mean, median, modus, simpangan baku, varians, nilai minimum, dan nilai maksimum.
3. Visualisasi data dengan menggunakan histogram, line chart, pie chart, bar chart, scatter plot, heatmap, dan boxplot
4. Pemeriksaan kualitas data seperti pengecekan *cell* yang *null*/ kosong dan pengecekan *outlier* menggunakan boxplot atau perhitungan statistik
5. Analisis hubungan antar variabel dengan menggunakan analisis korelasi atau *trend analysis*

Jenis Data dan Skala Pengukuran Variabel

Data dapat diartikan sebagai sebuah kumpulan informasi, fakta yang dapat berupa angka, simbol, maupun teks. Data dapat dikumpulkan dengan berbagai cara, seperti dari hasil survei, observasi, eksperimen, atau melalui tools seperti sensor digital. Data dalam *data mining* memiliki peran yang penting karena menjadi sumber informasi ataupun pengambilan Keputusan/ kebijakan. Data yang digunakan dalam analisis dapat berasal dari populasi maupun sampel. **Populasi** merupakan kumpulan/ himpunan dari keseluruhan elemen yang menjadi obyek penelitian/penyelidikan. Populasi memiliki ukuran populasi berupa angka atau nilai yang disebut dengan parameter, misalnya nilai rata-rata (μ), simpangan baku (σ). **Sampel** merupakan data yang diambil dari sebagain anggota populasi. Ukuran dalam sampel disebut statistik, yaitu angka/ nilai yang menggambarkan karakteristik dari sampel. Misalnya rata-rata ($\bar{x}$), simpangan baku (s).

A. Jenis-jenis Data

1. Berdasarkan Sifat

Pada jenis ini, data dibedakan menjadi 2 kelompok, yaitu data kualitatif dan kuantitatif. **Data kualitatif** adalah data yang menggambarkan karakteristik dari suatu variabel yang berupa kategori. Data kualitatif sering disebut dengan *categorical data*. Data kualitatif ini biasanya direpresentasikan dengan angka. Namun, tidak dapat dioperasikan secara matematis karena angka yang tertera hanya sebagai identitas, penanda, atau sebagai urutan saja. Contoh dari data kualitatif adalah jenis kelamin, warna, status mahasiswa (aktif, cuti, non aktif), status kepegawaian, dan jenjang pendidikan.

Data kuantitatif identik dengan hasil pencacahan dan pengukuran. Data kuantitatif ini berupa angka diskrit dan kontinu. Di mana data diskrit secara umum berasal dari hasil pencacahan seperti jumlah mahasiswa Sistem Informasi Angkatan 48, jumlah buku sains yang ada di perpustakaan. Sedangkan data kontinu berasal dari hasil pengukuran seperti tinggi badan, berat badan, tinggi badan, nilai mata kuliah, dan usia.

2. Berdasarkan Sumber

Data menurut sumber dapat dibedakan menjadi dua, yaitu data primer dan data sekunder. **Data primer** adalah data yang diperoleh dari hasil pengumpulan, atau pengamatan, atau pengukuran langsung oleh peneliti dari sumber pertama. Sebagai contoh adalah mahasiswa melakukan wawancara kepada dosen untuk mengumpulkan data penelitian, mahasiswa melakukan survei dengan menggunakan kuosioner terkait kepuasan teman sekelasnya terkait hasil presentasi yang dilakukan, atau bisa hasil eksperimen terkait pengukuran efektivitas jenis pupuk untuk menghambat pertumbuhan bakteri/ virus perusak daun tanaman.

Sedangkan **data sekunder** merupakan data yang diperoleh dari pihak lain atau sumber yang sudah ada sebelumnya. Data ini dapat berasal dari website, sistem, ataupun dokumen dari suatu organisas. Sebagai contoh data sekunder adalah ketika mahasiswa mengumpulkan data kemiskinan yang diperoleh dari website BPS, mahasiswa mengambil data rekap nilai suatu mata kuliah yang bersumber dari dosen pengampu, dan data prakira cuaca yang diperoleh dari BMKG.

3. Berdasarkan Waktu Pengumpulan

Data jenis ini terdiri dari data *cross section* dan data *time series*. **Data *cross section*** adalah data yang diambil/ diukur/ diamati satu waktu tertentu. Sedangkan **data *time series*** adalah data yang diukur/ diamati secara berkala dalam periode waktu tertentu. Data *time series* juga bisa diartikan sebagai hasil pengukuran periode saat ini dipengaruhi oleh hasil pengukuran periode sebelumnya, misalnya inflasi yang diukur tiap bulan selama satu tahun.

Sebagai ilustrasi, terdapat data curah hujan seperti yang tertera pada tabel di bawah ini.

Tabel 1. Data Curah Hujan Wilayah A Selama 6 Bulan

Bulan	Curah Hujan (mm)
Januari	150
Februari	145
Maret	175
April	200
Mei	220
Juni	190

Tabel 2. Data Curah Hujan di Beberapa Wilayah pada Bulan Januari

Wilayah	Curah Hujan (mm)
Wilayah A	175
Wilayah B	165
Wilayah C	175
Wilayah D	210
Wilayah E	220
Wilayah F	200

Tabel 1 merupakan contoh dari data *time series* karena pengukuran curah hujan dari satu wilayah selama 6 bulan, sehingga antar baris saling berkaitan. Sementara untuk Tabel 2 merupakan data *cross section*. Hal ini dikarenakan data diukur dalam satu waktu tertentu dan berbeda Lokasi/ wilayah.

Berdasarkan uraian di atas, dapat diberikan simpulan bahwa **data *cross section*** dan ***time series*** memiliki beberapa perbedaan, yaitu:

Tabel 3. Perbandingan *Cross Section* & *Time Series Data*

Cross Section Data	***Time Series Data***
Diukur satu waktu tertentu	Diukur secara berkala dalam satu periode waktu tertentu, misalnya setiap bulan selama dua tahun
Membandingkan banyak objek dalam satu waktu	Membandingkan antar waktu untuk satu objek tertentu
Sering digunakan untuk **menganalisis perbedaan antar objek**	Sering digunakan untuk menganalisis **trend atau pola perubahan dari waktu ke waktu (forecasting)**

Dari data *time series* dan *cross section* bisa melahirkan jenis data baru, yaitu data panel. Data ***panel*** merupakan gabungan antara data *cross section* dan *time series.* Di mana, terdapat banyak objek yang

diamati secara berkala (misal setiap bulan) selama periode waktu tertentu. Sebagai contoh adalah data inflasi bulanan selama satu tahun dari semua provinsi yang ada di Indonesia.

B. Variabel dan Skala Pengukuran Variabel

Suatu Kumpulan data/ *dataset* memiliki identitas yang disebut dengan variabel (peubah). Variabel adalah suatu ciri, karakteristik atau dari gejala suatu populasi atau sampel yang dapat mencapai lebih dari satu nilai. Proses pemberian simbol berupa angka terhadap setiap variasi karakteristik suatu variabel dari masing-masing unit yang diamati dalam statistik disebut pengukuran. Simbol yang digunakan untuk menggambarkan suatu variabel dapat berupa huruf latin, huruf Yunani, angka, atau gabungan antara huruf dan angka.

Jenis variabel terbagi menjadi variabel kualitatif (kategori) dan variabel kuantitatif. Definisi dari kedua jenis adalah:

1. Variabel kualitatif. Sering disebut data kategorikal, di mana variabel yang menggambarkan **sifat, kategori, atau kualitas**. Tidak dinyatakan dengan angka, melainkan berupa label atau deskripsi.
2. Variabel kuantitatif. Identik dengan data kuantitatif, di mana variabel yang berupa **angka** dan dapat diukur secara numerik. Bisa dihitung, dibandingkan, atau dianalisis dengan operasi aritmatika.

Sementara berdasarkan hasil pengukuran, variabel dibedakan menjadi variabel diskrit dan variabel kontinu. Adapun skala pengukuran yang digunakan untuk mengukur suatu variabel adalah:

1. Skala Nominal

Angka-angka yang disajikan pada skala nominal hanya sebagai nama penggolongan. Angka tersebut tidak mengukur besaran, tetapi hanya sebagai lambing atau pembeda. Sebagai contoh adalah jenis kelamin, daerah asal mahasiswa, dan jenis makanan/ minuman yang dijual di suatu restoran

2. Skala Ordinal

Suatu variabel berskala ordinal adalah peubah nominal yang penggolongannya dapat digunakan menyusun suatu urutan yang bermakna. Sebagai contoh adalah golongan pegawai untuk menentukan besaran gaji, jenjang pendidikan, stadium penyakit untuk menentukan keparahan pasien, dan

3. Skala Interval

Suatu nilai yang disajikan mempunyai sifat ordinal dengan tingkatan yang lebih spesifik (antar satu nilai dengan nilai yang lain memiliki jarak yang sama tetapi tidak bisa dibandingkan antara satu nilai dengan nilai yang lain. Selain itu, data berskala interval tidak memiliki nilai 0 mutlak (nilai nol bukan berarti tidak ada, melainkan masih memiliki makna). Sebagai contoh adalah suhu ruang, 0° C bukan berarti ruangan tidak memiliki suhu, 0° ini merupakan titik awal kondisi beku. Contoh yang lain adalah IQ, misalkan IQ mahasiswa A 100 dan B 120. Kedua IQ tersebut tidak bisa dibandingkan (B lebih cerdas dari A).

4. Skala Rasio

Skala rasio merupakan skala pengukuran tertinggi dari skala pengukuran variabel yang lainnya. Di mana, pada skala rasio memiliki semua sifat dari tiga skala sebelumnya. Data dengan berskala rasio mempunyai sifat skala selang. Kelebihan pada skala rasio adalah nilai-nilai pada skala rasio dapat

dibandingkan karena mempunyai nilai dasar yang mutlak, yaitu 0 memiliki makna yang sebenarnya (tidak mempunyai arti lain).

Tabel 4. Perbedaan Skala Pengukuran

Skala	Ciri/ Karakteristik			
	Indikasi perbedaan	Indikasi arah perbedaan	Indikasi besaran perbedaan	Nol mutlak
Nominal	√			
Ordinal	√	√		
Interval	√	√	√	
Rasio	√	√	√	√

Keterangan:

- Nominal dan ordinal termasuk data kualitatif
- Interval dan rasio termasuk data kuantitatif

Teknik *Sampling*

Dalam penelitian statistik, populasi yang sangat besar sering membuat peneliti tidak dapat meneliti seluruh anggotanya. Oleh karena itu digunakan *sampling*. ***Sampling*** dapat diartikan sebagai proses pemilihan sebagian anggota populasi untuk dijadikan **sampel penelitian** dengan tujuan memperoleh informasi mengenai karakteristik populasi secara keseluruhan. Pemilihan sampel yang tepat sangat penting karena mempengaruhi akurasi hasil penelitian. Teknik *sampling* yang baik akan menghasilkan sampel yang representatif, sehingga kesimpulan penelitian dapat menggambarkan kondisi populasi secara tepat. Penggunaan teknik *sampling* dalam penelitian memiliki beberapa tujuan utama, yaitu:

1. Menghemat waktu penelitian
2. Mengurangi biaya penelitian.
3. Mempermudah pengolahan data.
4. Tetap memperoleh informasi yang representatif, jika *sampling* dilakukan dengan benar dan tepat.

Ukuran *sampling* di dalam teknik *sampling* menjadi hal yang krusial dalam penelitian menggunakan data sampel. Ukuran sampel yang digunakan harus bisa mewakili dari jumlah anggota dalam populasi. ukuran sampel dapat dicari salah satunya dengan Slovin's formula, yaitu:

$$n = \frac{N}{1 + e^2 N}$$

Di mana:

N : Jumlah anggota populasi

n : Jumlah sampel

e : tingkat kesalahan (*margin of error*) -> 5% atau 10%

Selain menggunakan formula Slovin, apabila jumlah populasi diketahui, ukuran sampel dapat ditentukan dengan Krejcie Morgan dengan rumus:

$$n = \frac{\chi^2.N.P.(1-P)}{(N-1)e^2 + \chi^2.P.(1-P)}$$

Di mana:

N : Jumlah anggota populasi

n : Jumlah sampel

e : tingkat kesalahan (*margin of error*) -> 5% atau 10%

P : Proporsi pada populasi

χ^2 : nilai chi-square -> pada formula Krejcie Morgan menggunakan *degree of freedom* 1, dan α sesuai dengan e yang digunakan.

Terdapat dua jenis teknik *sampling*, yaitu *non-probability sampling* dan *probability sampling*. ***non-probability sampling*** adalah teknik pengambilan sampel di mana tidak semua anggota populasi memiliki peluang yang sama untuk dipilih. Teknik ini sering digunakan dalam penelitian eksploratif atau penelitian kualitatif. Sedangkan ***probability sampling*** adalah teknik pengambilan sampel di mana setiap anggota populasi memiliki peluang yang sama atau diketahui untuk dipilih sebagai sampel. Teknik ini biasanya digunakan dalam penelitian kuantitatif karena menghasilkan sampel yang lebih representatif. Pada bab ini, hanya dibahas detail mengenai *probability sampling* karena sesuai dengan tujuannya, yaitu analisis data kuantitatif dengan prinsip statistika.

Terdapat beberapa jenis *probability sampling*, yaitu seperti yang tertera dalam tabel di bawah ini.

1. *Simple Random Sampling*

Simple random sampling adalah teknik pengambilan sampel secara acak sehingga setiap anggota populasi memiliki peluang yang sama untuk dipilih. Teknik ini merupakan salah satu teknik yang paling sederhana, hanya saja teknik ini lebih cocok untuk data yang cenderung homogen. Cara pengambilan sampel dapat dilakukan dengan cara undian, tabel angka acak, atau melalu *random function* pada sebuah *tools*.

2. *Systematic Random Sampling*

Systematic sampling adalah teknik pengambilan sampel dengan memilih anggota populasi berdasarkan interval tertentu. Sama halnya dengan *simple random sampling*, teknik ini lebih cocok untuk data yang homogen. Langkah-langkah dalam teknik *sampling* ini adalah:

- menentukan ukuran sampel minimum
- menghitung interval *sampling*

  $$k = \frac{N}{n}$$
- memilih sampel berdasarkan interval
- Validasi sampel

3. *Stratified Random Sampling*

Stratified random sampling adalah teknik pengambilan sampel dengan cara membagi populasi menjadi beberapa kelompok (strata) sesuai dengan karakteristik tertentu yang ada dalam populasi.

Berbeda dengan *simple* dan *systematic random sampling*, teknik *sampling* ini lebih cocok untuk data yang heterogen. Terdapat Langkah-langkah dari teknik *sampling* ini, yaitu:

- Menentukan populasi
- Menentukan strata
- Menentukan ukuran sampel bisa menggunakan *proportional* maupun *non-proportional*.
- Menggabungkan sampel dari setiap strata
- Validasi sampel

4. *Cluster Sampling*

Cluster sampling adalah teknik pengambilan sampel dengan cara membagi populasi menjadi kelompok atau *cluster*, kemudian memilih beberapa *cluster* secara acak. Biasanya cluster terbentuk berbasis area/ wilayah. Misalkan berdasarkan sekolah, desa, kota, atau provinsi. Teknik ini cocok untuk data heterogen seperti *stratified random sampling*. Bedanya, untuk *stratified random sampling* setiap kelompok harus terpilih, sedangkan *cluster random sampling* boleh memilih sebagian kelompok, dengan hasil pemilihan harus memperhatikan representatif dan bias. Langkah-langkah dari teknik ini adalah:

1. Menentukan populasi
2. Membagi populasi menjadi cluster (kelompok)
3. Memilih sebagian cluster
4. Menentukan sampel dalam cluster terpilih
   Terdapat dua cara:
   Single-stage cluster sampling: semua anggota dalam cluster yang terpilih dijadikan sampel.
   Two-stage cluster sampling: dari cluster terpilih, dipilih lagi anggota secara acak, bisa menggunakan *proportional* maupun *non-proportional sampling*.
5. Validasi sampel

Summary:

Tabel 5. Jenis *Probability Sampling*

Jenis *Sampling*	Definisi	Cara Pengambilan Sampel	Contoh
Simple	Setiap anggota populasi memiliki peluang yang sama untuk dipilih.	Memilih sampel secara acak menggunakan undian, tabel angka random, atau tools.	Dari 200 siswa, dipilih 40 siswa secara acak.
Systematic	Sampel dipilih berdasarkan interval tertentu dari daftar populasi.	Menentukan angka awal secara acak lalu memilih setiap anggota ke-k.	Dari daftar 300 karyawan, memilih setiap karyawan ke-10, 20, 30, 40, dst.
Stratified	Populasi dibagi menjadi beberapa	Sampel diambil secara acak dari setiap strata.	4 strata masing-masing berjumlah 40, 30, 70, dan 60 akan diambil sampel sebanyak

	strata (kelompok) yang homogen.		100 dengan *proportional sampling*, sehingga hasil sample tiap strata adalah 20, 15, 35, dan 30.
Cluster	Populasi dibagi menjadi kelompok (cluster) biasanya berdasarkan wilayah atau unit alami.	Memilih beberapa cluster secara acak lalu meneliti anggota dalam cluster tersebut.	4 cluster masing-masing berjumlah 40, 30, 70, dan 60 akan diambil sampel sebanyak 100 *non-proportional sampling*, sehingga hasil sampel yang terpilih adalah cluster pertama dan keempat

Statistika Deskriptif

Statistika deskriptif adalah metode statistik yang digunakan untuk mengumpulkan, mengolah, merangkum, dan menyajikan data sehingga data menjadi lebih mudah dipahami. Statistika deskriptif tidak digunakan untuk membuat generalisasi ke populasi, tetapi hanya untuk mendeskripsikan data yang tersedia. Tujuan Statistika Deskriptif adalah:

- Merangkum data dalam bentuk yang lebih sederhana
- Menyajikan data dalam tabel atau grafik
- Mengetahui karakteristik utama data

Statistika deskriptif dapat disajikan dalam bentuk ukuran statistik mapupun visualisasi data. Ukuran statistik dapat terbagi menjadi ukuran pusat, ukuran Lokasi/ letak, dan ukuran keragaman/ penyimpangan. Berikut detail dari ukuran statistik:

Tabel 6. Macam-macam Ukuran Statistik

Kelompok	Jenis Ukuran Statistik	Formula Populasi	Formula Sampel
Ukuran Pusat	Mean	$\mu = \frac{\sum_{i=1}^{N} X_i}{N}$	$\bar{X} = \frac{\sum_{i=1}^{n} X_i}{n}$
	Median	$Letak: \frac{1}{2}(N+1)$ $Nilai: \frac{X_A + X_B}{2}$	$Letak: \frac{1}{2}(n+1)$ $Nilai: \frac{X_A + X_B}{2}$
	Mode	Frekuensi terbanyak	Frekuensi terbanyak
Ukuran Lokasi/ letak	Kuartil	$Letak\ Q_i: \frac{i}{4}(N+1)$ $Nilai\ Q_i:$ $X_A + nilai\ desimal\ (X_B - X_A)$	$Letak\ Q_i: \frac{i}{4}(n+1)$ $Nilai\ Q_i:$ $X_A + nilai\ desimal\ (X_B - X_A)$
	Persentil	$Letak\ P_i: \frac{i}{100}(N+1)$ $Nilai\ P_i:$ $X_A + nilai\ desimal\ (X_B - X_A)$	$Letak\ P_i: \frac{i}{100}(n+1)$ $Nilai\ P_i:$ $X_A + nilai\ desimal\ (X_B - X_A)$

Kelompok	Jenis Ukuran Statistik	Formula Populasi	Formula Sampel
Ukuran Keragaman	Ranga (R)	$R = X_{max} - X_{min}$	$R = X_{max} - X_{min}$
	Interquartile Range (IQR)	$IQR = Q_3 - Q_1$	$IQR = Q_3 - Q_1$
	Varians	$\sigma^2 = \frac{\sum(X_i - \mu)^2}{N}$	$S^2 = \frac{\sum(X_i - \bar{X})^2}{n-1}$
	Simpangan Baku	$\sigma = \sqrt{\frac{\sum(X_i - \mu)^2}{N}}$	$S = \sqrt{\frac{\sum(X_i - \bar{X})^2}{n-1}}$
	Koefisien Variasi	$CV = \frac{\sigma}{\mu} \times 100\%$	$CV = \frac{S}{\bar{X}} \times 100\%$

Contoh coding:

```
#import library
import numpy as np
from scipy import stats
#input angka ke dalam variabel X
X=[100,90,80,75,65,90,100,90,80,20,90,50,40,30,90]
mean = np.mean(X)
median = np.median(X)
modus = stats.mode(X, keepdims=False)
varians = np.var(X, ddof=1)      # varians sampel -> jika untuk populasi ddoff=0
std_dev = np.std(X, ddof=1)      # simpangan baku sampel -> -> jika untuk populasi ddoff=0
kuartil_1 = np.percentile(X, [25])
kuartil_2 = np.percentile(X, [50])
kuartil_3 = np.percentile(X, [75])
IQR = kuartil_3 - kuartil_1

print("Mean:", mean)
print("Median:", median)
print("Modus:", modus.mode)
print("Varians:", varians)
print("Simpangan Baku:", std_dev)
print("Kuartil (Q1):", kuartil_1)
print("Kuartil (Q2):", kuartil_2)
print("Kuartil (Q3):", kuartil_3)
print("Interquartile Range:", IQR)
```

Selain coding di atas, bisa juga menggunakan fungsi describe(), yang mana hasil yang muncul adalah jumlah baris, mean, median, simpangan baku, nilai minimum, nilai maksimum, kuartil 1, kuartil 2, dan kuartil 3.

Visualisasi Data

Visualisasi data adalah teknik penyajian data dalam bentuk grafik, diagram, atau plot sehingga informasi dalam data dapat lebih mudah dipahami, dianalisis, dan diinterpretasikan. Visualisasi sangat penting dalam *Exploratory Data Analysis* (EDA). Dalam statistika deskriptif, visualisasi digunakan untuk:

- melihat pola data
- memahami distribusi data
- membandingkan kategori
- mendeteksi outlier

Contoh Visualisasi data:

1. *Bar Chart*

Diagram batang atau *bar chart* digunakan untuk membandingkan nilai antar kategori. Sebagai contoh adalah jumlah mahasiswa per Program Studi

```
import pandas as pd
import matplotlib.pyplot as plt

# Membaca dataset dari CSV
df = pd.read_csv("mahasiswa.csv")

# Cek dataset
print(df)

plt.bar(df["Prodi"], df["Jumlah Mahasiswa"], color="red")

plt.title("Jumlah Mahasiswa di Telkom University")
plt.xlabel("Prodi")
plt.ylabel("Jumlah Mahasiswa")

plt.show()
```

2. *Pie Chart*

Pie chart digunakan untuk menunjukkan proporsi atau persentase kategori. Sebagai contoh adalah persentase mahasiswa per Program Studi

```
#Lanjutan coding bar chart
plt.pie(
    df["Jumlah Mahasiswa"],
    labels=df["Prodi"],
    autopct='%1.1f%%',
    startangle=90
)

plt.title("Persentase Mahasiswa di Telkom University")

plt.show()
```

3. Histogram

Histogram digunakan untuk melihat distribusi data numerik. Histogram membantu mengetahui:

- pola distribusi
- konsentrasi data
- penyebaran data

```
#lanjutan coding bar chart
plt.hist(df["Jumlah Mahasiswa"], bins=5, color='skyblue', edgecolor='black')

plt.title("Distribusi Jumlah Mahasiswa per Prodi")
plt.xlabel("Jumlah Mahasiswa")
plt.ylabel("Frekuensi")

plt.show()
```

4. Boxplot

Boxplot adalah salah satu visualisasi data yang dapat digunakan untuk mendeteksi outlier. Selain itu, Boxplot digunakan untuk melihat median, kuartil, dan penyebaran data

```
#lanjutan coding bar chart
plt.boxplot(df["Jumlah Mahasiswa"])

plt.title("Boxplot Jumlah Mahasiswa per Prodi")
plt.ylabel("Jumlah Mahasiswa")

plt.show()
```

5. Scatter Plot

Scatter plot digunakan untuk melihat hubungan antara dua variabel numerik. Sebagai contoh adalah Hubungan antara IPK dengan lamanya waktu belajar

```
import pandas as pd
import matplotlib.pyplot as plt

# Membaca dataset dari CSV
df = pd.read_csv("mahasiswa_belajar.csv")

# Cek data
print(df)

plt.scatter(df["Jam_Belajar"], df["IPK"], color="blue")

plt.title("Hubungan Jam Belajar dan IPK Mahasiswa")
plt.xlabel("Jam Belajar per Hari")
plt.ylabel("IPK")

plt.grid(True)
plt.show()
```

Deteksi *Outlier*

Outlier adalah data yang secara signifikan berbeda dari sebagian besar data lain dalam dataset. Bisa sangat lebih besar atau lebih kecil dibanding data lain. *Outlier* bisa muncul karena:

- Kesalahan pencatatan (error measurement)
- Variabilitas alami data
- Kondisi khusus yang memang nyata (rare event)

Deteksi *outlier* sangat penting dilakukan untuk dalam analisis data, karena:

- Mempengaruhi Mean dan Standar Deviasi
  Outlier dapat membuat rata-rata dan standar deviasi tidak representatif.
- Mendeteksi Kesalahan Data
  Outlier bisa menandakan kesalahan input atau pencatatan.
- Analisis Statistik Lebih Akurat
  Beberapa metode statistik sensitif terhadap outlier (misal regresi linear).

Selain dengan boxplot, *outlier* dapat dideteksi dengan pendekatan kuartil dengan formula:

$Lower\ bound = Q_1 - 1.5(IQR)$

$Upper\ bound = Q_3 - 3(IQR)$

Terdapat outlier jika terdapat minimal 1 nilai yang lebih kecil dari $lower\ bound$ atau lebih besar dari $upper\ bound$

```
#lanjutan dari ukuran statistik

lower = kuartil_1 - 1.5 * IQR
upper = kuartil_3 + 1.5 * IQR
outlier = [x for x in X if x < lower or x > upper]

print("Batas Bawah:", lower)
print("Batas Atas:", upper)
print("Outlier:", outlier)
```

Analisis Korelasi

Korelasi adalah metode statistik untuk mengukur kekuatan dan arah hubungan antara dua variabel numerik. Koefisien korelasi selalu antara -1 hingga 1 dengan ketentuan:

- 1 → hubungan positif sempurna
- -1 → hubungan negatif sempurna
- 0 → tidak ada hubungan linear

Rumus mendapatkan koefisien korelasi adalah:

Populasi:

$$\rho = \frac{\sum_{i=1}^{N}(X_i - \mu_X)\,(Y_i - \mu_Y)}{\sqrt{\sum_{i=1}^{N}(X_i - \mu_X)^2 \times \sum_{i=1}^{N}(Y_i - \mu_Y)^2}}$$

Sampel:

$$r = \frac{\sum_{i=1}^{N}(X_i - \bar{X}_X)\,(Y_i - \bar{X}_Y)}{\sqrt{\sum_{i=1}^{N}(X_i - \bar{X}_X)^2 \times \sum_{i=1}^{N}(Y_i - \bar{X}_Y)^2}}$$

ρ atau r	**Kekuatan Hubungan**	**Arah**
0.00 – 0.20	Sangat lemah	Positif atau negatif
0.20 – 0.40	Lemah	Positif atau negatif
0.40 – 0.60	Cukup kuat	Positif atau negatif
0.60 – 0.80	Kuat	Positif atau negatif
0.80 – 1.00	Sangat kuat	Positif atau negatif

Analisis korelasi tidak hanya menghitung koefisien korelasi, tetapi juga mengujinya secara statistik untuk menentukan apakah hubungan antara dua variabel signifikan atau hanya kebetulan. Tahapan pengujiannya adalah:

1. Hipotesis

   $H_0: \rho = 0$(ada korelasi)

$H_1: \rho \neq 0$(ada korelasi)

2. Statistik Uji
   Jika menggunakan Pearson, statistik uji bisa menggunakan p-value:
   - Koefisien korelasi → nilai kekuatan hubungan
   - p-value → uji signifikansi
3. Critical value -> α dengan nilai 0.01, atau 0.05, atau 0.1 (yang paling sering digunakan adalah 0.05)
4. Penarikan kesimpulan -> tolak H_0 ketika $p - value < \alpha$

```
import pandas as pd
from scipy.stats import pearsonr

# Baca dataset
df = pd.read_csv("mahasiswa_belajar.csv")

# Hitung korelasi Pearson
r, p_value = pearsonr(df["Jam_Belajar"], df["IPK"])

print("Koefisien Korelasi (r):", r)
print("p-value:", p_value)

# Keputusan uji
alpha = 0.05
if p_value < alpha:
print("Kesimpulan: Korelasi signifikan (tolak H0)")
else:
print("Kesimpulan: Korelasi tidak signifikan (gagal tolak H0)")
```

Referensi

Han, Jiaei, Jian Pei, and Hanghang Tong. 2023. *Data mining* Concepts and Techniques. 4th ed. Beth LoGiudice. Cambridge: Katey Birtcher.

Walpole, Ronald E., Myers, Raymond H., Myers, Sharon L., (2013), Probability & Statistics for Engineers & Scientists, 9th ed., Pearson Education, United States of America.